

# 基于深度学习 LSTM 神经网络的 全球股票指数预测研究<sup>\*</sup>

杨 青 王晨蔚

内容提要: 作为深度学习技术的经典模型之一,长短期记忆(LSTM)神经网络在挖掘序列数据长期依赖关系中极具优势。基于深度神经网络优化技术,本文构造了一个深层 LSTM 神经网络并将其应用于全球 30 个股票指数三种不同期限的预测研究。结果发现:①LSTM 神经网络具有很强的泛化能力,对全部指数不同期限的预测效果均很稳定;②相比三种对照模型(SVR、MLP 和 ARIMA),LSTM 神经网络具有优秀的预测精度,其对全部指数的平均预测精度在不同期限上均有提升;③LSTM 神经网络能够有效控制误差波动,相比三种对照模型,其对全部指数的平均预测稳定度在不同期限上亦均有提高。鉴于 LSTM 神经网络在预测精度和稳定度两方面的优势,其未来在金融预测等方向将有广阔的应用前景。

关键词: LSTM 神经网络;深度学习;股票指数预测

DOI: 10.19343/j.cnki.11-1302/c.2019.03.006

中图分类号: F222.3

文献标识码: A

文章编号: 1002-4565(2019)03-0065-13

## A Study on Forecast of Global Stock Indices Based on Deep LSTM Neural Network

Yang Qing & Wang Chenwei

**Abstract:** The Long-short Term Memory (LSTM) neural network, as one of the classic models in deep learning technology, is advantageous in mining long-term dependency of sequential data. Based on optimized technology of deep neural network, this paper constructs a deep LSTM neural network to forecast 30 stock indices in three scenarios with different horizons. The results show that i) the LSTM neural network is highly capable of generalization in financial forecast and can generate stable forecasts for 30 stock indices; ii) the LSTM neural network offers high accuracy in long and short-term forecasts in comparison with other three models (SVR, MLP and ARIMA), escalating the average accuracy of all indices for different scenarios; iii) the LSTM neural network can effectively control the error fluctuations and enhances the average stability of forecasts of all indices in the three scenarios compared to the other three models. In view of the advantages in terms of the forecast accuracy and stability, the LSTM neural network for sure will be widely used in the forecast for financial market in the coming days.

**Key words:** Long-short Term Memory(LSTM) Neural Network; Deep Learning; Forecast of Stock Indices

<sup>\*</sup> 本文获国家自然科学基金项目“中国债务资本市场的功能、结构和发展研究”(71661137008)的资助。感谢匿名评审专家和顾研博士的宝贵意见和建议。

## 一、引言

金融市场预测一直是金融领域关注的重点问题,在方法上可分为线性预测模型和非线性预测模型。线性预测模型包括移动平均自回归模型(ARIMA)、广义自回归条件异方差模型(GARCH)、指数平滑模型等,上述时间序列模型的应用使得金融市场预测研究取得了很大进步(刘国旗,2000<sup>[1]</sup>;惠晓峰等,2003<sup>[2]</sup>)。但是,鉴于金融时间序列的不确定性及高噪声特征,精准预测仍然非常困难,加之自变量和因变量之间的关系通常会随时间发生动态变化,致使传统时间序列模型很难有效进行金融市场预测。此外,仅适用于平稳序列建模也大幅限制了时间序列模型的应用与拓展。近年来,非线性模型逐渐取代了时间序列模型在金融预测方面的应用,其挖掘变量之间非线性关系的能力可以有效提高金融预测的表现。

目前,非线性预测模型主要包括基于人工神经网络(Artificial Neural Network,ANN)的各种模型、支持向量回归模型(Support Vector Regression,SVR)等。ANN作为人工智能领域的非线性方法,能够处理非线性、不连续和高频多维的数据,已被广泛应用于金融预测。Dhar等(2010)<sup>[3]</sup>利用经典多层感知器(Multi-Layer Perceptron,MLP)模型预测印度证券交易所股指收盘价;Ticknor(2013)<sup>[4]</sup>使用三层前馈神经网络预测微软公司和高盛集团的股价走势。但是,基于ANN的金融预测存在以下问题:①过拟合使得模型在训练集外预测能力变差;②优化过程存在梯度消失或梯度爆炸,使得神经网络无法有效学习;③局部极值问题,即无法找到全局最优解。近年来,深度学习技术不断发展,LeCun等(2015)<sup>[5]</sup>从技术角度论证了局部极值问题对于深层网络的影响可以被忽略,因而深度学习技术成为目前最前沿的有效机器学习方法。Heaton等(2016)<sup>[6]</sup>总结了将深度学习技术应用于金融市场研究的主要优势:①对输入变量的形式没有限制,与预测问题可能相关的信息均可被作为模型输入;②有效拟合输入变量间的非线性复杂关系,提高样本拟合程度;③避免浅层结构的过拟合问题。

深层神经网络模型(Deep Neural Network,DNN)能够根据数据特征进行一般化学习,在学习异质性信息过程中淡化无关因素、强化有效因素的作用,由此获得更好的金融预测效果。DNN主要包括循环神经网络(Recurrent Neural Network,RNN)及其衍生模型①、卷积神经网络(Convolutional Neural Network,CNN)和深度信念网络(Deep Belief Network,DBN)等模型。近年来,深度神经网络开始出现在金融预测中,Xiong等(2015)<sup>[7]</sup>利用LSTM神经网络对S&P 500波动率进行建模,结果表明LSTM神经网络对包含噪声的金融时间序列数据具有预测潜力;Shen等(2015)<sup>[8]</sup>使用连续受限玻尔兹曼机构造DBN对三种汇率进行预测,预测效果优于ARMA模型;Di Persio和Honchar(2016)<sup>[9]</sup>使用MLP、CNN和LSTM神经网络对S&P500第二天收盘价涨跌进行预测,发现基于CNN的预测误差最小;Di Persio和Honchar(2017)<sup>[10]</sup>将RNN、LSTM神经网络和GRU神经网络用于谷歌股价趋势预测,结果显示LSTM神经网络在金融序列预测方面具有优势。

上述研究尝试将深度学习方法应用于金融预测,但仅集中于基于多种方法对某一特定金融资产预测效果的边际改进,缺乏针对某一种DNN模型对金融资产预测普适性的探索验证。此外,将DNN应用于金融预测在全球范围尚属探索阶段,对国内市场的研究更是稀少(苏治等,2017)<sup>[11]</sup>。作为深度学习技术的经典模型之一,长短期记忆(Long-Short Term Memory,LSTM)神经网络在挖掘序列数据长期依赖关系中极具优势。因此,本文结合目前最前沿的DNN优化技术构造了一个LSTM神经网络,利用深层LSTM神经网络对全球30个股票指数(包括18个国内指数及12个国际

① 即长短期记忆神经网络(Long-Short Term Memory,LSTM)和门控循环单元(Gated Recurrent Unit,GRU)模型。

指数) 进行预测, 主要贡献在于: ①预测目标更加完备, 突破了现有股票指数预测研究; ②基于同一 LSTM 神经网络结构对 30 个指数进行预测效果评估, 证明 LSTM 神经网络在股指预测上具有优秀的泛化能力; ③将全球 30 个指数基于 LSTM 神经网络的预测效果与两种非线性模型( SVR 模型和 MLP 神经网络) 和一种线性模型( 针对每个指数构建的 ARIMA 模型) 在三种期限( 短期、中期、长期) 进行精度和稳定度的对比分析, 证明 LSTM 神经网络在全球股指预测上具有优越性。

## 二、模型构建

### (一) LSTM 神经元结构

LSTM 神经网络最早由 Hochreiter 和 Schmidhuber( 1997) <sup>[12]</sup> 提出, 由于能更好地发现长期依赖关系而被广泛用于处理序列信息, 如语音识别、机器翻译等。LSTM 每个神经元的结构见图 1 (Grave 2012) <sup>[13]</sup>, 其内部包括一个记忆储存( Cell) 和三个门控( Gates) 设置, Cell 记录神经元状态, 输入门( Input Gate) 和输出门( Output Gate) 用来接收、输出参数和修正参数, 遗忘门( Forget Gate) 用来控制上一单元状态的被遗忘程度。

### (二) LSTM 神经网络的构建

深层神经网络存在两种可能影响模型训练效果的问题, 一是梯度消失导致神经网络难以收敛, 二是过拟合导致测试集失效。研究表明, Batch-Normalization( BN) 能有效解决梯度消失问题, Dropout 技术通过阻止神经元共适应能够缓解过拟合问题。因此, 本文在设计 LSTM 神经网络时特别添加了 BN 层和 Dropout 层以优化神经网络结构。具体来说, 本文 LSTM 神经网络的主体结构包括三层 LSTM 神经层和两层全连接层, 每个 LSTM 层包括 200 个节点, 每层 LSTM 神经层前加入 BN 层, 其后加入 Dropout 层并将失活概率设为 0.2。本文构建的深层 LSTM 神经网络计算图结构见图 2, 虚线方框内表示神经网络结构。




图 1 LSTM 神经元结构示意图( Grave 2012)

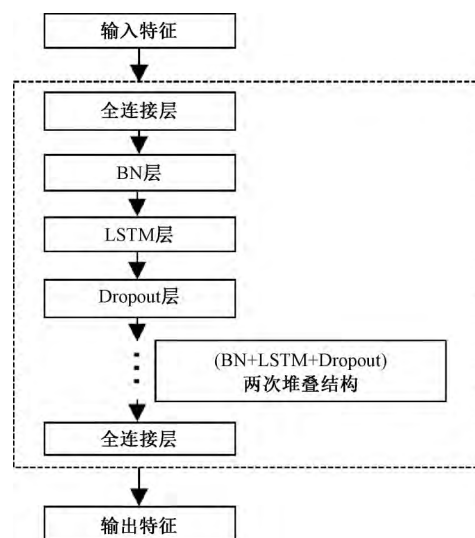


图 2 深层 LSTM 神经网络计算图结构

### (三) 训练方法及优化器选择

本文采用 Mini-Batch 方法训练 LSTM 网络。本文目标是预测股指未来收盘价, 故选取均方误差( Mean Square Error MSE) <sup>①</sup>作为损失函数。优化器方面, 本文采用 Adam 优化器( Adaptive Moment

① MSE 的一般形式为:  $J(\theta) = (1/2n) \sum_{i=1}^n (\hat{y}^{(i)} - y^{(i)})^2 = (1/2n) \sum_{i=1}^n (h_{\theta}(x^{(i)}) - y^{(i)})^2$ ;  $J(\theta)$  是损失函数  $\theta$  为神经网络参数  $n$  为训练集中样本个数,  $\hat{y}^{(i)}$  是预测值,  $y^{(i)}$  是真实值,  $h_{\theta}(x^{(i)})$  是用  $x$  作为网络输入对于  $y$  的预测值  $i$  表示第  $i$  个样本。

Estimation 适应性矩估计) ①进行优化训练。Adam 优化器由 Kingma 和 Ba(2015)<sup>[14]</sup> 提出,是目前最常用的算法(Sabour 等 2017<sup>[15]</sup>; Wang 等 2018<sup>[16]</sup>)。与其他自适应学习率算法相比,Adam 算法收敛速度更快、学习效果更为有效。本文基于 Python 语言环境,并以 PyTorch 作为深度学习框架进行训练及预测。

### 三、数据来源及样本选择

#### (一) 数据来源及描述

为了充分评估深度学习技术在全球股市预测上的适用性,本文同时选取中国大陆市场、美洲市场、欧洲市场和亚太市场中具有代表性、能够反映所在市场整体变动情况的 30 个股票指数进行研究。具体包括:18 个中国大陆股票市场指数(6 个上证指数、4 个深证指数、5 个中证指数、3 个中小板指数);12 个国际股票指数(3 个美洲股票指数、5 个欧洲股票指数、4 个亚太股票指数),指数名称见表 1。本文使用的变量包括:股指收盘价、开盘价、最高价、最低价、成交量、成交额<sup>②</sup>(仅国内指数)均为日度数据,数据来自 Wind 数据库。

#### (二) 总样本区间及训练集、测试集划分

本文采用如下标准选取股指数据集时间:剔除日成交量数据为 0 的初期数据,选取自日成交量数据存在至 2018 年 5 月 14 日的所有交易数据。为了观察不同预测方法对股指短期、中期、长期的预测效果,本文分别取各指数整体数据集的最后 20、最后 60、最后 250 个交易日作为短期、中期、长期预测的测试集,剔除测试集即为对应训练集。

表 1 选取指数名称

市场名称	指数名称
中国大陆股票市场	上证指数: 上证综指、上证 A 指、上证 B 指、上证 50、上证 180、上证 380; 深证指数: 深证成指、深证综指、深证 A 指、深证 B 指; 中证指数: 沪深 300、中证 100、中证 500、中证 800、中证 1000; 中小板指数: 中小板指、中小板综、中小 300。
美洲股票市场	道琼斯指数、标普 500 指数、纳斯达克 100 指数。
欧洲股票市场	德国 DAX 指数、英国富时 100 指数、法国 CAC40 指数、欧交所 100 指数、STOXX 指数。
亚太股票市场	日经 225 指数、韩国综合指数、富时新加坡 STI 指数、澳洲标普 200 指数。

### 四、预测方法及思路

#### (一) LSTM 神经网络方法及预测思路

LSTM 神经网络对每个指数的预测思路是,用历史 60 个交易日的数据信息对未来 1 天指数收盘价进行预测。通常对于未来 1 天交易日的收盘价,前 60 天的交易数据已经包含了足够信息,超过 60 个交易日的信息对第 61 天的影响非常小。模型输入方面,对于国内股票指数,本文使用股指收盘价、开盘价、最高价、最低价、成交量、成交额六个指标的日度数据作为模型输入;对于国际股票指数,本文使用股指收盘价、开盘价、最高价、最低价、成交量五个指标的日度数据作为模型输入。所有指数的 LSTM 神经网络输出均是未来 1 天指数收盘价的预测值, LSTM 神经网络模型计算图见图 3。

① 根据 Kingma 和 Ba(2015), Adam 优化算法一般形式为:  $m_t = \beta_1 m_{t-1} + (1 - \beta_1) g_t$ ;  $v_t = \beta_2 v_{t-1} + (1 - \beta_2) g_t^2$ ;  $\hat{m}_t = m_t / (1 - \beta_1^t)$ ;  $\hat{v}_t = v_t / (1 - \beta_2^t)$ ;  $\Theta_{t+1} = \Theta_t - (\alpha / (\sqrt{\hat{v}_t} + \epsilon)) \hat{m}_t$ ; 其中,  $g_t$  为梯度,  $m_t$  和  $v_t$  分别是对梯度的一阶矩估计和二阶矩估计,  $\hat{m}_t$  和  $\hat{v}_t$  是对  $m_t$  和  $v_t$  的校正,  $\beta_1$ 、 $\beta_2$  和  $\epsilon$  为默认参数,  $\beta_1 = 0.9$ ,  $\beta_2 = 0.999$ ,  $\epsilon = 10^{-8}$ 。

② 对于股票指数成交额指标, Wind 数据库仅有国内指数的成交额数据。



### (二) 非线性对照模型( SVR 模型及 MLP 神经网络) 及预测思路

本文将目前金融预测领域常用的两种机器学习模型( SVR 模型与 MLP 神经网络) 作为非线性对照模型。SVR 因其非线性近似能力, 在金融预测方面仍有一席之地( 戴稳胜等, 2008<sup>[17]</sup>; Hsu 等, 2009<sup>[18]</sup>; 苏治和傅晓媛, 2013<sup>[19]</sup>), 因此本文将  $\varepsilon$ -SVR 模型作为一种非线性对照模型<sup>①</sup>。如前所述, MLP 神经网络曾被大量用于金融预测, 因此本文构建三层经典 MLP 神经网络作为另一种非线性对照模型。两种非线性对照模型的预测思路为: 将股指收盘价、开盘价、最高价、最低价、成交量、成交额( 仅国内指数) 指标作为模型输入, 未来 1 天指数收盘价的预测值作为模型输出, 计算图见图 3。

### (三) 线性对照模型( ARIMA 模型) 及预测思路

时间序列模型的应用曾极大地促进了金融市场的预测研究, 其本身也成为后续各种预测新方法的经典对照模型( Kim 和 Won, 2018)<sup>[20]</sup>。因此, 本文选取 ARIMA(  $p, d, q$ ) 模型作为评估 LSTM 神经网络模型的一种对照模型。针对每个股票指数, ARIMA(  $p, d, q$ ) 模型的预测思路是: 首先对股指收盘价取对数, 通过 ADF 检验选取最优差分阶数获得平稳序列; 其次根据 AIC 或 BIC 法则选取模型参数(  $p, d, q$ ) 并进行序列建模; 最后由 ARIMA(  $p, d, q$ ) 模型进行序列预测, 模型流程图见图 4。

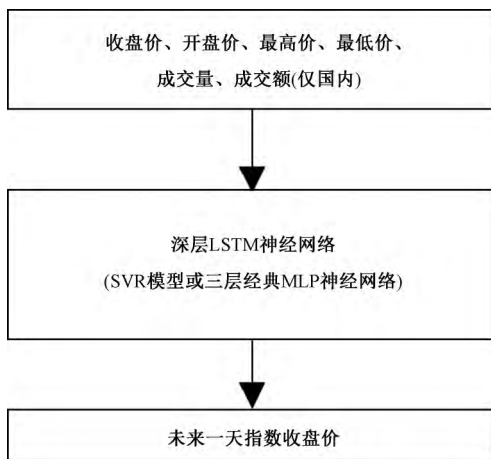


图 3 LSTM( SVR 或 MLP) 股指预测计算图

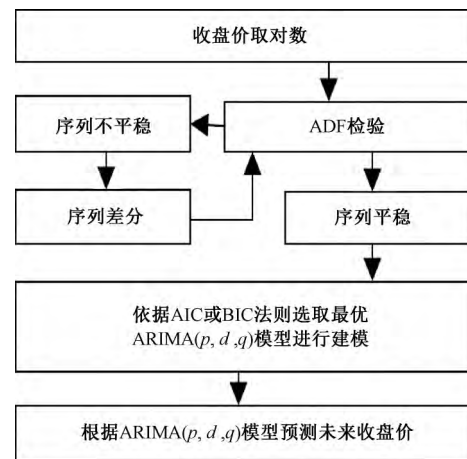


图 4 股指 ARIMA 模型选取流程图

## 五、实证研究

### (一) 测试集预测效果评估指标构建

鉴于本文是针对多个股票市场的股票指数进行预测, 因此构建相对误差指标进行测试集预测效果评估。**预测精度评估**采用百分比误差绝对值的平均值( Mean Absolute Percentage Error, MAPE)<sup>②</sup>, MAPE 值越小代表预测精度越高; **预测稳定度评估**采用百分比误差绝对值的

① 本文选用  $\varepsilon$ -SVR 模型作为非线性对照模型, RBF 作为核函数, 该方法中参数  $C$  为惩罚参数, 参数  $\varepsilon$  为不敏感损失参数, 本文分别选用  $C = \{1, 10, 20, 50, 100\}$ ,  $\varepsilon = \{1, 0.5, 0.1, 0.01, 0.001\}$  进行两两组合共计 25 组参数组合进行实验, 核参数选用默认值, 分别对 30 个股票指数 3 种预测期限( 共 90 个序列) 进行建模。文中所报告的 SVR 模型测试集预测评估结果选取该序列所有参数组合中 MAPE 值最小的参数组合结果, 即作为 SVR 模型最优预测结果。

② 百分比误差绝对值的平均值( MAPE) 计算方法:  $MAPE = (1/N) * \sum_{i=1}^N |(T_i - A_i) / A_i| * 100\%$ ; 其中  $T_i$  为预测值,  $A_i$  为真实值,  $N$  为样本个数。

标准差(Standard Deviation of Absolute Percentage Error,SDAPE)<sup>①</sup>,SDAPE 值越小代表预测稳定度越高。

## (二) 短期预测结果比较分析

本文采用 20 个交易日的长度衡量 LSTM 神经网络与 SVR 模型、MLP 神经网络、ARIMA 模型四种预测方法的短期表现。表 2 和表 3 分别报告了 18 个国内股票指数和 12 个国际股票指数的各指数测试集预测结果。

表 2 20 个交易日中国大陆股票市场指数预测结果 (%)

指标	指数名称	LSTM	SVR	MLP	ARIMA	指数名称	LSTM	SVR	MLP	ARIMA
MAPE	深证成指	0.92	2.09	1.19	1.78	上证综指	0.92	1.70	1.74	2.09
SDAPE		0.63	1.30	0.83	1.38		0.74	1.13	1.14	1.24
MAPE	深证综指	1.45	1.77	2.33	1.97	上证 A 指	1.06	1.70	1.75	2.10
SDAPE		0.78	0.94	1.50	1.39		0.80	1.12	1.12	1.25
MAPE	深证 A 指	1.00	1.63	2.05	2.02	上证 B 指	0.56	0.82	1.24	1.75
SDAPE		0.69	0.94	1.24	1.39		0.32	0.55	0.77	0.74
MAPE	深证 B 指	2.35	1.28	4.28	3.64	上证 50	1.58	1.94	1.70	2.47
SDAPE		1.09	0.94	1.40	1.71		0.95	1.37	1.25	1.36
MAPE	沪深 300	1.23	1.42	1.31	2.33	上证 180	1.28	1.67	1.38	2.22
SDAPE		0.82	1.14	0.93	1.41		0.96	1.30	1.28	1.30
MAPE	中证 100	1.29	1.85	1.37	2.42	上证 380	0.93	1.39	1.72	1.94
SDAPE		0.83	1.35	0.94	1.42		0.65	1.03	0.98	1.36
MAPE	中证 500	1.00	1.11	1.51	1.77	中小板指	1.82	1.73	1.91	2.31
SDAPE		0.69	0.97	0.95	1.23		0.96	1.40	1.04	1.74
MAPE	中证 800	1.12	1.14	1.22	2.18	中小板综	1.02	1.67	1.50	1.89
SDAPE		0.67	0.99	0.72	1.33		0.66	0.99	1.03	1.41
MAPE	中证 1000	1.13	1.24	1.60	1.91	中小 300	1.31	1.49	1.55	2.00
SDAPE		0.85	0.83	1.05	1.23		0.86	1.15	0.99	1.45

表 3 20 个交易日国际股票市场指数预测结果 (%)

指标	指数名称	LSTM	SVR	MLP	ARIMA	指数名称	LSTM	SVR	MLP	ARIMA
MAPE	道琼斯指数	0.85	0.75	1.51	0.98	欧交所 100	0.28	1.19	0.63	1.87
SDAPE		0.64	0.57	0.88	0.67		0.19	0.65	0.35	0.95
MAPE	标普 500	1.02	0.88	1.28	1.04	STOXX 50	0.50	0.79	0.68	1.25
SDAPE		0.60	0.60	0.72	0.79		0.32	0.55	0.41	1.04
MAPE	纳斯达克 100	1.36	1.18	1.68	1.43	日经 225	0.67	0.69	1.96	2.04
SDAPE		0.94	0.97	1.03	1.35		0.44	0.42	0.54	1.18
MAPE	德国 DAX	0.66	0.80	1.70	2.08	韩国综合指数	0.70	0.59	0.76	1.08
SDAPE		0.50	0.53	0.95	1.50		0.44	0.45	0.51	0.80
MAPE	英国富时 100	0.88	1.23	2.11	2.85	富时新加坡 STI	0.64	1.23	1.31	2.55
SDAPE		0.92	0.79	1.02	1.62		0.52	0.69	0.80	0.95
MAPE	法国 CAC40	0.34	1.48	1.41	2.85	澳洲标普 200	0.48	0.77	1.21	2.65
SDAPE		0.20	0.57	0.31	1.41		0.37	0.47	0.81	1.75

对于 18 个国内股票指数,在预测精度方面,16 个指数 LSTM 神经网络的 MAPE 值均小于三种对照模型,即对于 16 个国内股票指数,LSTM 神经网络均能提高预测精度。深证 B 指和中小板指的 LSTM 神经网络预测精度高于 MLP 神经网络和 ARIMA 模型,仅低于 SVR 模型。在预测稳定度方面,16 个指数 LSTM 神经网络的 SDAPE 值均小于三种对照模型,即对于 16 个国内股票指数,LSTM 神经网络均能提高预测稳定度。深证 B 指和中证 1000 指数的 LSTM 神经网络预测稳定度高

① 百分比误差绝对值的标准差(SDAPE)计算方法:  $SDAPE = \sqrt{(1/N) \sum_{i=1}^N ((T_i - A_i) / A_i - MAPE)^2}$ ; 其中  $T_i$  为预测值, $A_i$  为真实值, $N$  为样本个数。

于 MLP 神经网络和 ARIMA 模型,仅略低于 SVR 模型。因而,针对国内指数短期预测,深层 LSTM 神经网络明显占优,能够提高绝大部分指数的短期预测精度和预测稳定度。

以 ARIMA 模型为基准,仅深层 LSTM 神经网络在全部国内指数的短期预测中表现出预测精度及稳定度的全面提升。SVR 模型对深证成指的预测精度不及 ARIMA 模型,对上证 50 的预测稳定度不及 ARIMA 模型;MLP 神经网络在预测精度和稳定度方面分别有 3 个和 2 个指数不及 ARIMA 模型。MLP 神经网络与 SVR 模型在短期预测国内指数时,没有一方面表现出绝对优越性,其中 6 个指数的 SVR 预测精度低于 MLP 神经网络,10 个指数的 SVR 预测稳定度低于 MLP 神经网络。

对于 12 个国际股票指数,在预测精度方面,8 个指数的 LSTM 神经网络 MAPE 值均小于三种对照模型,即对 8 个国际股票指数而言,LSTM 神经网络均能提高预测精度。对于道琼斯指数、标普 500、纳斯达克 100 指数及韩国综合指数,LSTM 神经网络的预测精度高于 MLP 神经网络和 ARIMA 模型,仅略微低于 SVR 模型。在预测稳定度方面,9 个指数的 LSTM 神经网络 SDAPE 值均小于三种对照模型,即对 9 个国际股票指数而言,LSTM 神经网络均能提高预测稳定度。对于道琼斯指数、日经 225 及英国富时 100 指数,LSTM 神经网络的预测稳定度均高于 MLP 神经网络和 ARIMA 模型,仅略低于 SVR 模型。因而,针对国际指数短期预测,深层 LSTM 神经网络明显占优,能够提高绝大部分指数的短期预测精度和预测稳定度。

以 ARIMA 模型为基准,深层 LSTM 神经网络和 SVR 模型在全部国际指数的短期预测中表现出预测精度及稳定度的全面提升。MLP 神经网络分别在 3 个指数的预测精度和 1 个指数的预测稳定度上不及 ARIMA 模型。MLP 神经网络与 SVR 模型在短期预测国际指数时,没有一方面表现出绝对优越性,其中 3 个指数的 SVR 预测精度低于 MLP 神经网络,3 个指数的 SVR 预测稳定度低于 MLP 神经网络。

综合全球 30 个股票指数,LSTM 神经网络与三种对照方法在预测精度 90 个对比结果中<sup>①</sup>,LSTM 神经网络在 84 个结果上表现出精度提升;在预测稳定度 90 个对比结果中,LSTM 神经网络在 85 个结果上表现出稳定度提升,深层 LSTM 神经网络具有指数短期预测优越性。

表 4 报告了国内、国际及全部指数测试集的短期平均预测效果评估结果。国内指数组 LSTM 神经网络的平均 MAPE 值为 1.22%,相比 SVR、MLP 和 ARIMA 模型,平均预测精度分别提高 0.31%、0.52%和 0.93%;LSTM 神经网络的平均 SDAPE 值为 0.78%,相比 SVR、MLP 和 ARIMA 模型,平均预测稳定度分别提高 0.30%、0.29%和 0.58%。国际指数组 LSTM 神经网络的平均 MAPE 值为 0.70%,相比 SVR、MLP 和 ARIMA 模型,平均预测精度分别提高 0.27%、0.66%和 1.19%;LSTM 神经网络的平均 SDAPE 值为 0.51%,相比 SVR、MLP 和 ARIMA 模型,平均预测稳定度分别提高 0.10%、0.19%和 0.66%。总体来看,全部 30 个指数 LSTM 神经网络的平均 MAPE 值为 1.01%,预测精度比 SVR、MLP 和 ARIMA 模型分别提高 0.29%、0.58%和 1.04%;LSTM 神经网络的平均 SDAPE 值为 0.67%,预测稳定度比 SVR、MLP 和 ARIMA 模型分别提高 0.22%、0.25%和 0.61%。因此,就股票指数短期预测的整体水平而言,深层 LSTM 神经网络在预测精度及稳定度两方面优于三种对照模型。

### (三) 中期预测结果比较分析

本文采用 60 个交易日的时间长度衡量 LSTM 神经网络与 SVR 模型、MLP 神经网络、ARIMA 模型四种预测方法的中期表现。表 5 和表 6 分别报告了 18 个国内股票指数和 12 个国际股票指数各

<sup>①</sup> 进行任一期限指数预测时,30 个指数使用四种模型建模得到 120 个 MAPE 值(120 个 SDAPE 值),将每个指数的 LSTM 神经网络 MAPE 值(SDAPE 值)与三种对照模型的 MAPE 值(SDAPE 值)分别相减,共有 90 个预测精度(稳定度)对比结果。

表 4 短期预测结果精度与稳定度对比 (%)

MAPE 平均值	国内指数	国际指数	全部指数	SDAPE 平均值	国内指数	国际指数	全部指数
LSTM	1.22	0.70	1.01	LSTM	0.78	0.51	0.67
SVR	1.53	0.97	1.31	SVR	1.08	0.61	0.89
MLP	1.74	1.35	1.59	MLP	1.06	0.69	0.92
ARIMA	2.15	1.89	2.05	ARIMA	1.35	1.17	1.28
LSTM-SVR	-0.31	-0.27	-0.29	LSTM-SVR	-0.30	-0.10	-0.22
LSTM-MLP	-0.52	-0.66	-0.58	LSTM-MLP	-0.29	-0.19	-0.25
LSTM-ARIMA	-0.93	-1.19	-1.04	LSTM-ARIMA	-0.58	-0.66	-0.61

表 5 60 个交易日中国大陆股票市场指数预测结果 (%)

指标	指数名称	LSTM	SVR	MLP	ARIMA	指标	LSTM	SVR	MLP	ARIMA
MAPE	深证成指	1.37	3.03	2.22	5.35	上证综指	1.29	4.10	1.78	4.95
SDAPE		1.14	2.01	1.89	2.35		1.03	2.08	2.10	2.60
MAPE	深证综指	1.50	4.34	2.96	6.97	上证 A 指	1.10	4.14	1.83	4.93
SDAPE		1.32	2.05	2.45	2.56		1.08	1.86	2.10	2.61
MAPE	深证 A 指	1.84	4.30	2.71	5.99	上证 B 指	0.97	1.96	2.06	1.23
SDAPE		1.34	2.05	2.29	2.35		0.80	1.21	1.67	0.88
MAPE	深证 B 指	1.37	1.27	2.65	2.61	上证 50	1.70	3.98	1.86	11.81
SDAPE		1.24	1.08	1.92	1.50		1.53	2.29	1.80	4.16
MAPE	沪深 300	1.43	2.99	1.73	5.36	上证 180	1.59	4.16	1.88	8.22
SDAPE		1.20	1.84	1.69	3.09		1.68	2.01	1.98	3.21
MAPE	中证 100	1.21	3.16	1.87	8.82	上证 380	1.74	3.17	2.29	5.06
SDAPE		1.10	2.25	1.75	3.87		1.64	1.95	2.42	2.20
MAPE	中证 500	1.54	2.46	2.32	5.69	中小板指	1.37	3.01	1.92	5.56
SDAPE		1.41	1.98	2.35	2.21		1.07	1.98	1.56	2.76
MAPE	中证 800	1.07	2.48	1.73	2.98	中小板综	1.61	3.86	1.89	5.40
SDAPE		0.83	1.85	1.75	2.03		1.30	1.69	1.92	2.27
MAPE	中证 1000	1.41	3.78	2.19	8.12	中小 300	1.15	2.12	1.55	6.10
SDAPE		1.32	2.36	2.38	2.76		1.05	1.63	1.30	2.56

表 6 60 个交易日国际股票市场指数预测结果 (%)

指标	指数名称	LSTM	SVR	MLP	ARIMA	指标	LSTM	SVR	MLP	ARIMA
MAPE	道琼斯指数	1.17	1.17	1.96	1.61	欧交所 100	0.65	1.28	0.85	3.81
SDAPE		0.83	0.97	1.57	1.13		0.69	0.91	0.73	1.95
MAPE	标普 500	0.98	1.09	1.77	1.60	STOXX 50	0.76	0.95	1.24	1.54
SDAPE		0.75	0.92	1.53	1.02		0.71	0.79	0.96	1.06
MAPE	纳斯达克 100	1.42	1.58	2.66	3.29	日经 225	0.88	1.48	1.91	1.74
SDAPE		1.14	1.11	1.58	2.17		0.71	1.04	0.93	1.21
MAPE	德国 DAX	0.87	2.21	2.34	1.81	韩国综合指数	0.86	0.94	1.29	3.71
SDAPE		0.75	1.56	1.40	1.49		0.63	0.79	1.06	1.23
MAPE	英国富时 100	0.75	1.66	1.49	2.04	富时新加坡 STI	0.69	1.00	1.19	2.58
SDAPE		0.56	1.22	0.90	1.77		0.61	0.78	0.81	1.49
MAPE	法国 CAC40	0.63	1.37	1.19	3.48	澳洲标普 200	0.51	0.80	0.98	1.58
SDAPE		0.56	1.01	0.67	2.22		0.37	0.54	0.74	1.09

指数测试集的预测结果。

对于 18 个国内股票指数,在预测精度方面,17 个指数的 LSTM 神经网络 MAPE 值均小于三种对照模型,即对 17 个国内股票指数而言,LSTM 神经网络均能提高预测精度。对于深证 B 指,LSTM 神经网络预测精度优于 MLP 与 ARIMA 模型,仅略低于 SVR 模型。在预测稳定度方面,17 个指数的 LSTM 神经网络 SDAPE 值均小于三种对照模型,即对 17 个国内股票指数而言,LSTM 神经网络均能提高预测稳定度。对于深证 B 指,LSTM 神经网络的预测稳定度高于 MLP 神经网络和 ARIMA 模型,仅略微低于 SVR 模型。总体来看,针对国内指数中期预测,深层 LSTM 神经网络明显占优,



能够提高绝大部分指数的中期预测精度和预测稳定度。

以 ARIMA 模型为基准,仅深层 LSTM 神经网络在全部国内指数的中期预测中表现出预测精度及稳定度的全面提升。SVR 模型在上证 B 指的预测精度和稳定度上均不及 ARIMA 模型;MLP 神经网络分别有 2 个指数的预测精度和 4 个指数的预测稳定度不及 ARIMA 模型。MLP 神经网络与 SVR 模型在预测国内指数时,没有一方面表现出绝对优越性,其中 16 个指数的 SVR 预测精度低于 MLP 神经网络,8 个指数的 SVR 预测稳定度低于 MLP 神经网络。

对于 12 个国际股票指数,在预测精度方面,全部指数的 LSTM 神经网络 MAPE 值均小于其余三种模型,即对全部国际股票指数而言,LSTM 神经网络均能提高预测精度。在预测稳定度方面,11 个指数的 LSTM 神经网络 SDAPE 值均小于三种对照模型,即对 11 个国际股票指数而言,LSTM 神经网络均能提高预测稳定度。对于纳斯达克 100 指数,LSTM 神经网络的预测稳定度均高于 MLP 神经网络和 ARIMA 模型,仅略微低于 SVR 模型。因而,针对国际指数中期预测,深层 LSTM 神经网络显示了绝对的精度优越性,且能够提高绝大部分指数的预测稳定度。

以 ARIMA 模型为基准,仅深层 LSTM 神经网络在全部国际股票指数的中期预测中表现出预测精度及稳定度的全面提升。SVR 模型在德国 DAX 指数预测精度及稳定度上不及 ARIMA 模型;MLP 神经网络分别有 4 个指数的预测精度和 2 个指数的预测稳定度不及 ARIMA 模型。MLP 神经网络与 SVR 模型在预测国际指数时,亦没有一方面表现出绝对优越性。其中,3 个指数的 SVR 预测精度低于 MLP 神经网络,5 个指数的 SVR 预测稳定度低于 MLP 神经网络。

综合全球 30 个股票指数来看,在预测精度 90 个对比结果中,LSTM 神经网络在 89 个结果上表现出精度提升;在预测稳定度 90 个对比结果中,LSTM 神经网络在 88 个结果上表现出稳定度提升,深层 LSTM 神经网络具有指数中期预测优越性。

表 7 报告了国内、国际及全部指数测试集的中期平均预测效果评估结果。国内指数组 LSTM 神经网络的平均 MAPE 值为 1.40%,相比 SVR、MLP 和 ARIMA 模型,平均预测精度分别提高 1.84%、0.68%和 4.44%;LSTM 神经网络的平均 SDAPE 值为 1.23%,相比 SVR、MLP 和 ARIMA 模型,平均预测稳定度分别提高 0.67%、0.74%和 1.33%。国际指数组 LSTM 神经网络的平均 MAPE 值为 0.85%,相比 SVR、MLP 和 ARIMA 模型,平均预测精度分别提高 0.45%、0.72%和 1.55%;LSTM 神经网络的平均 SDAPE 值为 0.69%,相比 SVR、MLP 和 ARIMA 模型,平均预测稳定度分别提高 0.28%、0.38%和 0.79%。总体来看,全部 30 个股票指数 LSTM 神经网络的平均 MAPE 值为 1.18%,预测精度比 SVR、MLP 和 ARIMA 模型分别提高 1.28%、0.70%和 3.29%;LSTM 神经网络的平均 SDAPE 值为 1.01%,预测稳定度比 SVR、MLP 和 ARIMA 模型分别提高 0.51%、0.59%和 1.11%。因此,就股票指数中期预测的整体水平而言,深层 LSTM 神经网络在预测精度及稳定度两方面优于三种对照模型。

表 7 中期预测结果精度与稳定度对比 (%)

MAPE 平均值	国内指数	国际指数	全部指数	SDAPE 平均值	国内指数	国际指数	全部指数
LSTM	1.40	0.85	1.18	LSTM	1.23	0.69	1.01
SVR	3.24	1.29	2.46	SVR	1.90	0.97	1.53
MLP	2.08	1.57	1.88	MLP	1.96	1.07	1.61
ARIMA	5.84	2.40	4.47	ARIMA	2.55	1.49	2.13
LSTM-SVR	-1.84	-0.45	-1.28	LSTM-SVR	-0.67	-0.28	-0.51
LSTM-MLP	-0.68	-0.72	-0.70	LSTM-MLP	-0.74	-0.38	-0.59
LSTM-ARIMA	-4.44	-1.55	-3.29	LSTM-ARIMA	-1.33	-0.79	-1.11

## (四) 长期预测结果比较分析

本文采用 250 个交易日的时间长度衡量 LSTM 神经网络与 SVR 模型、MLP 神经网络、ARIMA 模型四种预测方法的长期表现。表 8 和表 9 分别报告了 18 个国内股票指数和 12 个国际股票指数各指数测试集的预测结果。

表 8 250 个交易日中国大陆股票市场指数预测结果 (%)

指标	指数名称	LSTM	SVR	MLP	ARIMA	指数名称	LSTM	SVR	MLP	ARIMA
MAPE	深证成指	1.13	1.84	2.14	6.84	上证综指	0.87	1.85	1.36	4.75
SDAPE		0.97	1.64	1.59	3.59		0.91	1.76	1.28	3.07
MAPE	深证综指	1.16	2.83	2.57	3.19	上证 A 指	0.83	1.86	1.40	4.76
SDAPE		1.14	2.33	2.50	2.35		0.78	1.77	1.29	3.08
MAPE	深证 A 指	1.15	2.79	2.10	3.21	上证 B 指	0.80	1.54	1.69	3.08
SDAPE		1.14	2.39	2.12	2.36		0.73	1.15	1.39	1.92
MAPE	深证 B 指	0.78	1.28	2.16	4.87	上证 50	0.99	1.37	1.64	14.75
SDAPE		0.72	0.94	1.60	2.62		0.80	1.33	1.23	5.92
MAPE	沪深 300	1.04	1.26	1.43	11.93	上证 180	1.14	1.75	1.52	11.70
SDAPE		0.89	1.07	1.17	5.26		1.07	1.35	1.37	4.98
MAPE	中证 100	1.01	1.36	1.73	15.55	上证 380	1.28	2.57	2.17	2.92
SDAPE		0.83	1.18	1.32	6.54		1.00	2.33	2.19	2.04
MAPE	中证 500	1.20	2.25	2.13	3.43	中小板指	1.01	1.87	1.62	9.87
SDAPE		1.10	1.86	1.95	2.36		0.93	1.77	1.20	4.82
MAPE	中证 800	0.99	1.32	1.33	9.07	中小板综	1.17	2.47	1.72	3.37
SDAPE		0.78	1.14	1.13	4.27		1.12	2.02	1.73	2.32
MAPE	中证 1000	1.62	3.58	2.60	8.82	中小 300	1.44	1.52	1.56	5.03
SDAPE		1.55	2.58	2.22	6.67		1.30	1.26	1.31	3.34

表 9 250 个交易日国际股票市场指数预测结果 (%)

指标	指数名称	LSTM	SVR	MLP	ARIMA	指数名称	LSTM	SVR	MLP	ARIMA
MAPE	道琼斯指数	1.16	1.17	1.50	9.98	欧交所 100	0.64	0.87	1.01	2.04
SDAPE		1.07	1.15	1.35	5.90		0.63	0.74	0.74	1.35
MAPE	标普 500	0.98	0.99	1.67	6.91	STOXX 50	0.57	1.04	1.11	3.70
SDAPE		0.91	0.89	1.10	4.37		0.55	0.89	1.09	2.79
MAPE	纳斯达克 100	1.24	1.35	1.95	8.99	日经 225	1.04	0.84	1.54	7.97
SDAPE		1.13	1.18	1.36	5.92		0.74	0.67	1.08	3.89
MAPE	德国 DAX	0.70	1.25	1.67	2.93	韩国综合指数	0.64	0.67	1.99	9.30
SDAPE		0.67	1.17	1.33	1.80		0.54	0.53	1.38	2.67
MAPE	英国富时 100	0.58	1.12	1.13	1.97	富时新加坡 STI	0.70	0.84	1.04	3.78
SDAPE		0.48	1.20	0.91	1.73		0.51	0.64	0.79	2.79
MAPE	法国 CAC40	0.69	0.93	1.07	2.02	澳洲标普 200	0.58	0.70	0.77	2.10
SDAPE		0.62	0.73	0.77	1.37		0.50	0.50	0.60	1.03

对于 18 个国内股票指数,在预测精度方面,全部指数的 LSTM 神经网络 MAPE 值均小于三种对照模型,即对 18 个国内股票指数而言,LSTM 神经网络均能提高预测精度。预测稳定度方面,17 个指数的 LSTM 神经网络 SDAPE 值均小于三种对照模型,即对 17 个国内股票指数而言,LSTM 神经网络均能提高预测稳定度。对于中小板 300 指数,LSTM 神经网络的预测稳定度高于 MLP 神经网络和 ARIMA 模型,仅略微低于 SVR 模型。因而,针对国内股票指数长期预测,深层 LSTM 神经网络显示出了绝对的精度优越性,且能够提高绝大部分指数的长期预测稳定度。

以 ARIMA 模型为基准,仅深层 LSTM 神经网络在全部国内股票指数的长期预测中表现出预测精度及稳定度的全面提升。SVR 模型和 MLP 神经网络虽然在预测精度方面超越了 ARIMA 模型,但其二者分别有 2 个指数的预测稳定度低于 ARIMA 模型。MLP 神经网络与 SVR 模型在长期预测国内股票指数时,没有一方面表现出绝对优越性,其中 10 个指数的 SVR 预测精度低于 MLP 神经

网络,10 个指数的 SVR 预测稳定度低于 MLP 神经网络。

对于 12 个国际股票指数,在预测精度方面,11 个指数的 LSTM 神经网络 MAPE 值均小于三种对照模型,即对 11 个国际股票指数而言,LSTM 神经网络均能提高预测精度。对于日经 225 指数,LSTM 神经网络的预测精度高于 MLP 神经网络和 ARIMA 模型,仅略微低于 SVR 模型。在预测稳定度方面,8 个指数的 LSTM 神经网络 SDAPE 值均小于三种对照模型,即对 8 个国际股票指数而言,LSTM 神经网络均能提高预测稳定度,对其余 4 个指数的预测稳定效果仅略低于 SVR 模型,但均优于 MLP 神经网络和 ARIMA 模型。因而,针对国际股票指数长期预测,深层 LSTM 神经网络能够提高大部分指数的长期预测精度和稳定度。

以 ARIMA 模型为基准,深层 LSTM 神经网络、SVR 模型和 MLP 神经网络对全部国际股票指数长期预测的预测精度及稳定度均优于 ARIMA 方法,显示出在长期预测中非线性模型预测的优越性。

综合全球 30 个股票指数来看,在预测精度 90 个对比结果中,LSTM 神经网络在 89 个结果上表现出精度提升;在预测稳定度 90 个对比结果中,LSTM 神经网络在 85 个结果上表现出稳定度提升,深层 LSTM 神经网络具有指数长期预测优越性。

表 10 报告了国内、国际及全部指数测试集的长期平均预测效果评估结果。国内指数组 LSTM 神经网络的平均 MAPE 值为 1.09%,相比 SVR、MLP 和 ARIMA 模型,平均预测精度分别提高 0.87%、0.74%和 5.97%;LSTM 神经网络的平均 SDAPE 值为 0.99%,相比 SVR、MLP 和 ARIMA 模型,平均预测稳定度分别提高 0.67%、0.60%和 2.76%。国际指数组 LSTM 神经网络的平均 MAPE 值为 0.79%,相比 SVR、MLP 和 ARIMA 模型,平均预测精度分别提高 0.19%、0.58%和 4.35%;LSTM 神经网络的平均 SDAPE 值为 0.70%,相比 SVR、MLP 和 ARIMA 模型,平均预测稳定度分别提高 0.16%、0.35%和 2.27%。总体来看,全部 30 个指数 LSTM 神经网络的平均 MAPE 值为 0.97%,预测精度比 SVR、MLP 和 ARIMA 模型分别提高 0.60%、0.67%和 5.32%;LSTM 神经网络的平均 SDAPE 值为 0.87%,预测稳定度比 SVR、MLP 和 ARIMA 模型分别提高 0.47%、0.50%和 2.57%。因此,就股票指数长期预测的整体水平而言,深层 LSTM 神经网络在预测精度及稳定度两方面优于三种对照模型。

表 10 长期预测结果精度与稳定度对比 (%)

MAPE 平均值	国内指数	国际指数	全部指数	SDAPE 平均值	国内指数	国际指数	全部指数
LSTM	1.09	0.79	0.97	LSTM	0.99	0.70	0.87
SVR	1.96	0.98	1.57	SVR	1.66	0.86	1.34
MLP	1.83	1.37	1.64	MLP	1.59	1.04	1.37
ARIMA	7.06	5.14	6.29	ARIMA	3.75	2.97	3.44
LSTM-SVR	-0.87	-0.19	-0.60	LSTM-SVR	-0.67	-0.16	-0.47
LSTM-MLP	-0.74	-0.58	-0.67	LSTM-MLP	-0.60	-0.35	-0.50
LSTM-ARIMA	-5.97	-4.35	-5.32	LSTM-ARIMA	-2.76	-2.27	-2.57

#### (五) LSTM 神经网络预测效果比较分析

综合全球 30 个股票指数不同期限的预测表现,本文发现 LSTM 神经网络在股票指数预测方面具有优秀的泛化能力。具体来说,全部 30 个股票指数利用同一 LSTM 神经网络结构进行不同期限的预测,其预测误差与误差波动不随预测期限长度或股指种类变化而发生剧烈变动,因此证明了 LSTM 神经网络具有强大的自我学习能力及优秀的泛化能力。

在预测精度方面,以 ARIMA 模型为基准,预测时间段越长,ARIMA 模型失效越严重,而 LSTM 神经网络具有较为稳定的预测误差范围。LSTM 神经网络比 ARIMA 模型对全部指数的平均预测

精度分别提高 1.04%(短期)、3.29%(中期)和 5.32%(长期)。以 SVR 模型和 MLP 神经网络两种非线性模型为基准,LSTM 神经网络在三种不同预测期限上均有不同程度的预测精度提升。相比于 SVR 模型,LSTM 神经网络对全部指数的平均预测精度分别提高 0.29%(短期)、1.28%(中期)和 0.60%(长期);相比于 MLP 神经网络,LSTM 神经网络模型对全部指数的平均预测精度分别提高 0.58%(短期)、0.70%(中期)和 0.67%(长期)。

在预测误差稳定度方面,LSTM 神经网络能够有效地控制误差波动。对于本文选取的全球 30 个股票指数,LSTM 神经网络预测得到的 SDAPE 值短期、中期、长期均稳定在 1%左右。以 ARIMA 模型为基准,LSTM 神经网络模型对全部指数的平均预测稳定度分别提高 0.61%(短期)、1.11%(中期)和 2.57%(长期)。以 SVR 模型和 MLP 神经网络两种非线性模型为基准,LSTM 神经网络在三种不同预测期限上均有不同程度的预测稳定度提升。相比于 SVR 模型,LSTM 神经网络对全部指数的平均预测稳定度分别提高 0.22%(短期)、0.51%(中期)和 0.47%(长期);相比于 MLP 神经网络,LSTM 神经网络对全部指数的平均预测稳定度分别提高 0.25%(短期)、0.59%(中期)和 0.50%(长期)。

## 六、结论及政策建议

本文结合目前最前沿的深度学习神经网络优化技术构造了一个深层 LSTM 神经网络,将其应用于全球 30 个股票指数的预测分析,并与三种对照模型(SVR 模型、MLP 神经网络和 ARIMA 模型)预测结果进行了短期、中期及长期三种不同期限的对比,得出以下结论:①LSTM 神经网络在股票指数预测方面具有泛化能力。②在预测精度方面,LSTM 神经网络具有优秀的长短期预测准确性。相比于 SVR、MLP 和 ARIMA 模型,LSTM 神经网络对全球 30 个股票指数的平均预测精度在短期分别提高 0.29%、0.58%和 1.04%,在中期分别提高 1.28%、0.70%和 3.29%,在长期分别提高 0.60%、0.67%和 5.32%。预测期限越长,LSTM 神经网络相比于 ARIMA 模型显示出的精度优越性越明显。③在预测稳定度方面,LSTM 神经网络能够有效地控制预测误差波动,提高预测稳定度。相比于 SVR、MLP 和 ARIMA 模型,LSTM 神经网络对全部 30 个股票指数的平均预测稳定度在短期分别提高 0.22%、0.25%和 0.61%,在中期分别提高 0.51%、0.59%和 1.11%,在长期分别提高 0.47%、0.50%和 2.57%。LSTM 神经网络优秀的预测稳定度能够在预测指数时给出更窄的置信区间,提供更有效的预测结果。因此,LSTM 神经网络在预测精度及稳定度两方面均显示出优越性。此外,鉴于 LSTM 神经网络强大的自我学习能力、良好的泛化能力及模型的高度可调节性,LSTM 神经网络在金融预测的发展中具有广阔前景。

本文在金融预测方向利用深度学习前沿技术进行积极探索,针对全球 30 个股票指数验证了 LSTM 神经网络的广泛适用性和预测优越性,为将深度学习技术广泛应用于金融预测、形成新的研究范式提供了实践经验。鉴于神经网络的高度可调节性,未来本文在技术方面可以有多种改进方向,例如添加多种非同质信息作为神经网络输入,附加小波分解或主成分分析等数据预处理技术进行模型优化,或从神经网络本身进行结构优化等。将深度学习技术应用于金融预测只是金融智能化发展的第一步,后续还可以在两大主题上继续探索:一是在金融风险管理领域引入深度学习神经网络的前沿方法,利用大数据的优势更有效地进行风险识别和风险测度;二是将深度学习方法应用于投资领域,帮助金融机构快速识别投资机会,推动我国金融市场智能化投资的发展。

### 参考文献

- [1] 刘国旗. 非线性 GARCH 模型在中国股市活动预测中的应用研究[J]. 统计研究, 2000(1): 49-52.

- [2] 惠晓峰, 等. 基于时间序列 GARCH 模型的人民币汇率预测[J]. 金融研究, 2003(5): 99-105.
- [3] Dhar S, Mukherjee T, Ghoshal A K. Performance Evaluation of Neural Network Approach in Financial Prediction: Evidence from Indian Market[A]. 2010 International Conference on. IEEE[C], 2010: 597-602.
- [4] Ticknor J L. A Bayesian Regularized Artificial Neural Network for Stock Market Forecasting[J]. Expert Systems with Applications, 2013(14): 5501-5506.
- [5] LeCun Y, Bengio Y, Hinton G. Deep learning[J]. Nature, 2015: 436-444.
- [6] Heaton J B, Polson N G, Witte J H. Deep Learning in Finance[J]. arXiv preprint arXiv: 1602.06561, 2016.
- [7] Xiong R, Nichols E P, Shen Y. Deep learning stock volatility with google domestic trends[J]. arXiv preprint arXiv: 1512.04916, 2015.
- [8] Shen F, Chao J, Zhao J. Forecasting Exchange Rate Using Deep Belief Networks and Conjugate Gradient Method[J]. Neurocomputing, 2015: 243-253.
- [9] Di Persio L, Honchar O. Artificial Neural Networks Architectures for Stock Price Prediction: Comparisons and Applications[J]. International Journal of Circuits, Systems and Signal Processing, 2016(10): 403-413.
- [10] Di Persio L, Honchar O. Recurrent Neural Networks Approach to the Financial Forecast of Google Assets[J]. International Journal of Mathematics and Computers in Simulation, 2017(11): 7-13.
- [11] 苏治, 卢曼, 李德轩. 深度学习的金融实证应用: 动态, 贡献与展望[J]. 金融研究, 2017(5): 111-126.
- [12] Hochreiter S, Schmidhuber J. Long Short-term Memory[J]. Neural Computation, 1997(8): 1735-1780.
- [13] Graves A. Supervised Sequence Labelling with Recurrent Neural Networks[M]. Springer Berlin Heidelberg, 2012: 5-13.
- [14] Kingma D P, Ba J. Adam: A Method for Stochastic Optimization[A]. International Conference on Learning Representations (ICLR)[C], 2015(5).
- [15] Sabour S, et al. Dynamic Routing Between Capsules[J]. Neural Information Processing Systems, 2017: 3856-3866.
- [16] Wang S, et al. Deep Parametric Continuous Convolutional Neural Networks[A]. Computer Vision and Pattern Recognition[C], 2018: 2589-2597.
- [17] 戴稳胜, 吕奇杰, 徐曼文. 股指期货信息内含股价变动信息的挖掘——小波框架与支持向量回归的金融建模应用[J]. 统计研究, 2008(2): 78-83.
- [18] Hsu S H, et al. A Two-stage Architecture for Stock Price Forecasting by Integrating Self-organizing Map and Support Vector Regression[J]. Expert Systems with Applications, 2009(4): 7947-7951.
- [19] 苏治, 傅晓媛. 核主成分遗传算法与 SVR 选股模型改进[J]. 统计研究, 2013(5): 54-62.
- [20] Kim H Y, Won C H. Forecasting the Volatility of Stock Price Index: A Hybrid Model Integrating Lstm with Multiple Garch-type Models[J]. Expert Systems with Applications, 2018: 25-37.

#### 作者简介

杨青, 女, 复旦大学金融研究院教授、博士生导师。研究方向为深度学习与金融风险管理、公司治理等。

王晨蔚, 女, 复旦大学经济学院在读博士研究生。研究方向为深度学习与金融预测。

(责任编辑: 郭明英)